

Brecha de género en el ingreso laboral en Bogotá

Problem Set 1 — Sección 2



Big Data y Machine Learning para Economía Aplicada (MECA 4107) · Universidad de los Andes

Mauricio José Aragón Ramírez (código: 201729052)

Jonathan Camilo Cadena Silva (código: 202315765)

Julio Esteban Flórez Pérez (código: 202615893)

● Result Overview

Resultado principal de la Sección 2 — antes de entrar en la metodología

Brecha condicional preferida

-18.0%

IC 95%: -19.7% a -16.4%

Diferencia de picos de edad

4.7 años

Hombres 50.1 vs. mujeres 45.3 (IC no se traslapan)

La brecha de género no condicional es -19.7%, pero se mueve entre -25.8% y -15.3% según los controles incluidos -- la especificación preferida (edad, educación, horas, vinculación, formalidad y tamaño de firma) la estima en -18.0%, coeficiente recuperado de forma idéntica por la descomposición de Frisch-Waugh-Lovell.

El resto de esta presentación muestra por qué la brecha se mueve tanto: las cuatro especificaciones estimadas, la descomposición FWL, los perfiles edad-ingreso por género, y qué controles pueden estar sesgando la estimación.

● Agenda

- 1 Motivación: una brecha que se mueve
- 2 Cuatro especificaciones estimadas
- 3 Descomposición Frisch-Waugh-Lovell
- 4 Perfiles edad-ingreso por género
- 5 Bad controls y lectura económica

● Contexto: datos utilizados

Fuente y restricciones de la muestra usada en las cuatro especificaciones

Observaciones

N = 14,637 observaciones


Misma muestra en las 4 especificaciones (comparación válida entre modelos anidados)

La muestra proviene de la GEIH 2018 – Bogotá, restringida a personas ocupadas mayores de edad. Tras eliminar observaciones con datos faltantes en las variables usadas (tipo de vinculación, educación, formalidad, tamaño de firma, estrato, composición del hogar), quedan 14,637 observaciones — exactamente las mismas para las cuatro especificaciones estimadas.

Los errores estándar bootstrap y los intervalos de confianza se calculan con R=1,000 réplicas no paramétricas sobre esta misma muestra.

• ¿Por qué la brecha estimada cambia tanto?

- El coeficiente de Female pasa de -0.220 (no condicional) a -0.298 al agregar edad y educación, y luego cae a -0.199 y -0.166 al sumar horas, vinculación, formalidad, tamaño de firma, estrato y hogar.
- Ese vaivén no es ruido: cada control puede estar absorbiendo parte del efecto de género, ya sea porque es un canal legítimo o porque es en sí mismo resultado de la discriminación (bad control).
- Esta sección evalúa cuál de las cuatro especificaciones es más defendible y por qué -- antes de fijar un solo número como "la" brecha de género.



Especificación	Ecuación (variable dependiente: $\log(w)$)
No condicional	$\beta_0 + \beta_1 \cdot \text{Female}$
Cond. 1 (edad+educ)	$+ \beta_2 \cdot \text{Edad} + \beta_3 \cdot \text{Edad}^2 + \beta_4 \cdot \text{Educ}$
Cond. segura	$+ \text{Horas} + \text{Vinculación_fac} + \text{Formal_fac} + \text{TamañoFirma_fac}$
Cond. extra	$+ \text{Estrato_fac} + \text{JefeHogar} + (\text{Niños} < 5 \times \text{Female})$


● Comparación de las cuatro especificaciones

Variable dependiente: $\log(\text{ingreso laboral mensual})$ · GEIH 2018, Bogotá

Variable	No condicional	Cond. 1 (edad+educ)	Cond. segura	Cond. extra
Female (coef.)	-0.220***	-0.298***	-0.199***	-0.166***
SE analítico	(0.0138)	(0.0119)	(0.0104)	(0.0105)
SE bootstrap	(0.0139)	(0.0121)	(0.0105)	(0.0105)
IC 95% bootstrap	(-0.247, -0.193)	(-0.321, -0.275)	(-0.220, -0.179)	(-0.187, -0.147)
R ² ajustado (ajuste dentro de muestra)	0.017	0.272	0.482	0.554
Efecto exacto: $(e^{\beta}-1) \times 100$	-19.7%	-25.8%	-18.0%	-15.3%

*** $p < 0.01$. Errores estándar entre paréntesis. Efecto exacto = $(e^{\beta} - 1) \times 100$. Cond. segura: edad, edad², educación, horas trabajadas, vinculación, formalidad, tamaño de firma. Cond. extra: + estrato, jefatura de hogar, niños < 5 años × Female.

● Perfiles edad-ingreso, por género



Edad pico hombres

50.1 años

Edad pico mujeres

45.3 años


Especificación segura + interacciones $\text{Female} \times \text{edad}$ y $\text{Female} \times \text{edad}^2$. Los IC 95% bootstrap (48.5–51.8 vs. 44.1–46.9) no se traslapan: la diferencia de picos es significativa aunque ningún coeficiente de interacción lo sea individualmente.

• ¿Por qué FWL recupera el mismo coeficiente?

- El teorema de Frisch-Waugh-Lovell dice que el coeficiente de Female en la regresión completa es idéntico al de regresar los residuos de $\log(\text{ingreso})$ sobre los residuos de Female, ambos limpios del efecto de los controles.
- En los datos: -0.19896113 en la regresión completa y -0.19896113 en la FWL residualizada -- coinciden hasta el séptimo decimal, porque es una identidad algebraica de MCO, no una aproximación empírica.
- El error estándar bootstrap (0.01053) es casi idéntico al analítico (0.01045): no hay evidencia de heterocedasticidad severa que invalide los supuestos clásicos de MCO en esta especificación.

Coef. idéntico: -0.19896 (regresión completa = FWL)

SE analítico vs. bootstrap, por especificación



● **Bad controls: por qué la brecha no es un solo número**

- La brecha salta de -19.7% a -25.8% al controlar por educación: las mujeres de la muestra tienen, en promedio, mayor nivel educativo, lo que enmascaraba parte de la penalización real en la comparación bruta.
- Al agregar horas, vinculación laboral y formalidad, la brecha cae a -18.0%: son posibles canales de la propia discriminación (segregación ocupacional, acceso desigual al empleo formal), no características predeterminadas -- condicionar por ellas puede subestimar la brecha total.
- Jefatura de hogar y niños menores de 5 son un caso más sutil (collider bias): quién es jefe de hogar depende en parte de quién gana más, así que controlar por ello puede sesgar el coeficiente en cualquier dirección, no solo atenuarlo.

En síntesis

- Brecha no condicional: -19.7%; se mueve entre -25.8% y -15.3% según los controles incluidos.
- Especificación preferida (segura): -18.0%, recuperado de forma idéntica por la descomposición FWL.
- Picos de edad distintos por género (hombres 50.1 vs. mujeres 45.3 años); los IC 95% no se traslapan.
- Horas, vinculación y formalidad son posibles mediadores; jefatura de hogar y niños<5 son posibles colliders.