

Predicción del ingreso laboral

Problem Set 1 — Sección 3



Big Data y Machine Learning para Economía Aplicada (MECA 4107) · Universidad de los Andes

Mauricio José Aragón Ramírez (código: 201729052)

Jonathan Camilo Cadena Silva (código: 202315765)

Julio Esteban Flórez Pérez (código: 202615893)

● Resumen de resultados

Resultado principal de la Sección 3 — antes de entrar en la metodología

Modelo con mejor desempeño

Segunda Especificación Adicional

Especificación flexible con interacciones de género, educación, formalidad y estructura del hogar.

RMSE fuera de muestra

VC: 0.524
LOOCV: 0.508

Error porcentual aproximado del 71%

Los modelos con especificaciones de las secciones 1 y 2 de este taller tuvieron bajo desempeño fuera de muestra. Para la predicción se requiere mayor complejidad/flexibilidad de los modelos para reducir el error de predicción. La predicción mejoró con mayor flexibilidad, pero el error sigue siendo Elevado.

El resto de esta presentación muestra la metodología y los datos utilizados. Así como los principales resultados.

● Agenda

- 1 Contexto: Datos utilizados y metodología empleada
- 2 Motivación: Resultados de especificaciones previas
- 3 Modelo seleccionado
- 4 Importancia de variables
- 5 Implicaciones para la autoridad tributaria

- **Contexto: Datos utilizados y metodología empleada**

Muestra de entrenamiento

10,175 Observaciones

Chunks 1-7 (70%)

Muestra de validación

4,462 Observaciones

Chunks 8-10 (30%)

La muestra viene de los datos de la GEIH 2018 – Bogotá. Está restringida a personas ocupadas mayores de edad y cuyos ingresos se encuentran entre el 0.5% y el 99.5% de la distribución de ingresos mensuales (50,000-15,250,000). La muestra total consta de 14,637 observaciones.

Para la evaluación de desempeño se utiliza el **RMSE** fuera de muestra (validación cruzada con **división 70/30**), y criterios de selección: **AIC** y **BIC**.

● Motivación: Resultados de especificaciones previas I

Variable dependiente: $\log(\text{ingreso laboral mensual})$ · GEIH 2018, Bogotá


Modelo	No. Parámetros	RMSE Entrenamiento	RMSE Validación	Error pct. Aprox	AIC	BIC
B1. Sec1 Incondicional	3	0.81	0.83	129.71	24,612	24,640
B2. Sec1 Condicional	9	0.73	0.76	112.96	22,498	22,570
B3. Sec2 Incondicional	2	0.83	0.85	133.33	25,004	25,025
B4. Sec2 Preferida	20	0.60	0.62	85.75	18,460	18,612
M1. Complejidad moderada	65	0.51	0.53	69.76	15,309	15,786
M2. Interacciones Género	80	0.50	0.52	68.84	15,059	15,645
M3. Polinomios Flexibles	101	0.50	0.52	68.49	14,919	15,656
M4. Interacciones Avanzadas	74	0.52	0.54	71.29	15,633	16,175
M5. Alta Dimensión	105	0.52	0.54	71.09	15,593	16,359

Seleccionamos el modelo de interacciones de género, al observar que un aumento significativo en la complejidad no reduce notablemente el **RMSE de validación** y sí es penalizado por el **BIC**.

● Motivación: Resultados de especificaciones previas II

Valores Predichos vs. Observados (Muestra de Validación)

Línea roja discontinua = Predicción perfecta (45°)



- La gráfica presenta el desempeño de los diferentes modelos utilizados. Si la predicción fuera perfecta: las predicciones estarían sobre la diagonal.
- Los modelos de las secciones anteriores tienen un bajo desempeño dada su simplicidad, incluso, el incondicional de género es lo más parecido, entre estos, a una predicción con la media.
- A medida que aumenta la complejidad, empieza a disminuir el RMSE fuera de muestra. Aunque los modelos más complejos no muestran mejoras significativas contra el seleccionado (M2).

● Modelo seleccionado

$$\begin{aligned}
 \ln(\text{Ingreso}_i) = & \beta_0 + \beta_1 \text{Mujer}_i + \sum_{p=1}^2 \gamma_p \text{Edad}_i^p + \sum_{p=1}^2 \delta_p (\text{Mujer}_i \times \text{Edad}_i^p) \\
 & + \sum_{p=1}^2 \theta_p \text{HorasTrabajadas}_i^p + \theta_3 \text{TiempoTrabajo}_i \\
 & + \sum_{j=2}^7 \lambda_j \text{Educación}_{ji} + \sum_{j=2}^7 \phi_j (\text{Educación}_{ji} \times \text{Edad}_i) + \sum_{j=2}^7 \psi_j (\text{Mujer}_i \times \text{Educación}_{ji}) \\
 & + \alpha_1 \text{Formal}_i + \alpha_2 (\text{Mujer}_i \times \text{Formal}_i) \\
 & + \sum_{k=2}^6 \rho_k \text{Relab}_{ki} + \sum_{m=2}^5 \pi_m \text{TamañoFirma}_{mi} + \sum_{s=2}^6 \tau_s \text{Estrato}_{si} + \sum_{o=1}^0 \mu_o \text{Oficio}_{oi} \\
 & + \eta_1 \text{JefeHogar}_i + \eta_2 \text{NiñosUnder10}_i + \eta_3 \text{TotalPersonas}_i + \varepsilon_i
 \end{aligned}$$

RMSE – Validación cruzada 70/30

0.5237

RMSE – Leave One Out Cross Validation

0.5076


Para evitar el costo computacional de correr aproximadamente 15,000 regresiones, se utilizó la propiedad que se cumple para modelos OLS al estimar LOOCV:

$$LOOCV = \frac{1}{n} \sum_{i=1}^n \left(\frac{e_i}{1 - h_{ii}} \right)^2$$

● Importancia de las variables


- Se estimó la importancia de cada predictor sobre el modelo final mediante **permutación aleatoria de variables**. Para cada variable X_j , se desordenaron sus valores en el conjunto de validación, preservando el resto de las covariables.
- La importancia se mide como el **aumento promedio del RMSE** después de la permutación (10 repeticiones).
- Si al romper la relación entre una variable y el ingreso el error aumenta sustancialmente, la variable contiene información predictiva relevante.

Las **horas trabajadas**, la **ocupación**, el **estrato** y el **tamaño de la firma** son los predictores con mayor contribución a la precisión del modelo.



● Efecto de las horas trabajadas

- La dependencia parcial revela una relación **cóncava** entre horas trabajadas e ingreso laboral.
- El ingreso predicho crece fuertemente al acercarse a una jornada completa, el máximo se alcanza alrededor de **75 horas semanales**. Después, el efecto marginal de una hora adicional disminuye progresivamente.
- Para niveles muy altos de horas trabajadas, el ingreso predicho comienza a caer, reflejando rendimientos decrecientes.



● Implicaciones para la autoridad tributaria

- El modelo captura patrones económicos relevantes, pero no permite estimar ingresos individuales con alta precisión. Un **RMSE fuera de muestra** superior a 0.52 indica que una fracción sustancial del ingreso sigue dependiendo de factores no observados o no disponibles en la base de datos (**esto implica un error aproximado del 71%**).
- El modelo puede servir para identificar contribuyentes cuyo ingreso declarado resulta inconsistente con su perfil socioeconómico y laboral, orientando de manera más eficiente los recursos de fiscalización y seguimiento a casos específicos. La integración de otras variables disponibles para varias observaciones puede ser más valiosa que aumentar la sofisticación del modelo predictivo.

La predicción es suficientemente informativa para detectar riesgo tributario, pero no para reemplazar la información observada de cada contribuyente.

El mayor potencial para la administración tributaria está en la focalización de auditorías y no en la estimación automática de ingresos individuales.

En síntesis

- La capacidad predictiva mejora sustancialmente al incorporar interacciones y relaciones no lineales.
- El modelo seleccionado alcanza el mejor balance entre precisión predictiva y complejidad (RMSE = 0.524).
- Las horas trabajadas son el principal determinante de la predicción y muestran rendimientos decrecientes.
- Aún con el mejor modelo, el error sigue siendo elevado, por lo que la predicción es útil para focalización de riesgo y no para estimar ingresos individuales con precisión.
- La principal lección no es qué modelo predice mejor, sino cuánto ingreso permanece sin explicar incluso en especificaciones altamente flexibles.